蒸馏预算该花在哪条能力轴上？紧凑多模态大模型的能力轴选择依赖于量尺

方法名称： Argmax Retention Profiling (ARP) for distillation budget allocation

研究动机

这项工作针对的是一类做法，可以叫做「跨轴退化归因」：拿一个模型家族，测它在若干条不同能力轴上各掉了多少分，按掉分多少给能力轴排序，然后对排第一的那条轴采取行动（取 argmax）。问题不在于单独某一条轴测得准不准，而在于把几条轴放到同一把尺子上的那一步。每条轴都由自己的一套题目来读出，这套题目叫探针（probe）；每个探针各有自己的瞎猜得分（chance floor，即完全乱答能拿到的分）、能达到的上限、题目数量和测量噪声。POPE 是物体幻觉的评测协议，它是一场正负样本均衡的是非题投票，所以有一个答题器根本不看图、一律回答"no"，它也能拿到大约 0.50 分。指代表达式定位（grounding）这条轴的判定方式是：预测框与真实框的重叠度 IoU（Intersection over Union，交并比）达到 0.5 才算对；此时把框放在图像正中、面积取训练集框面积的中位数，这种做法几乎什么都拿不到，大约只有 0.02。于是，前者掉十分和后者掉十分，所代表的能力损失完全不是一回事，而标准的汇报流程里没有任何环节能把两者换算过来。

具体场景是「把多模态大模型（MLLM）缩小之后的能力审计」。最接近的两篇前作把这个问题的实际形态暴露得很清楚。‘arxiv:2511.17487v2‘（Downscaling Intelligence）把整个跨轴排序压在一句话上 —— 从 8B 到 0.6B，定位能力掉 48%、感知相似度降 38% —— 但它没有说这个百分比是以什么为分母，没有对瞎猜得分做校正（这个得分由它自己的 AutoConverter 多选题转换引入），也没给出任何一个随机种子或误差棒；后文还悄悄换成了绝对数值。‘arxiv:2512.16921v1‘（AuditDM）确实在同一家族内比较了不同规模的成员，甚至发现有些类别上 28B 模型还不如 3B 模型；但它给失败模式排序的依据，是用强化学习训出一个审计器之后，看它与参考集成（reference-ensemble）预言器的分歧频率有多高。这样一来，排序继承的是预言器的行为，而不是一把说得清楚的尺子。两篇的排序都只报了一个点，没有列出其他同样站得住脚的答案。

让这件事成为结构性问题、而不只是写得粗糙的，是这个排序最终被用来干什么。它不是一张描述性的图表，而是一次离散的挑选：挑完之后，一笔中途无法打断的训练预算会全部花在那一条轴上。定向蒸馏这一支的工作，在训练开始之前就把轴定死了 —— 其中 ‘openalex:W4415269743‘ 选组合推理，‘arxiv:2608.01263v2‘ 固定一组感知探针基底 —— 所以审计点到哪条轴，算力就去哪条轴，而且不会回来。假设检查点、题目、模型原始回答全都不动，只是换一把同样站得住脚的尺子，排第一的轴就变了，那么决定这笔预算落在哪里的，就是探针的量尺性质，而不是模型本身。

最近一年有三件事，把这个问题从「可以争论」变成了「可以测量」。第一，同家族的规模阶梯现在是现成发布的，不必自己搭：Qwen2.5-VL 有 3B 和 7B，InternVL3 有 1B/2B/8B，LLaVA-OneVision 有 0.5B/7B，这就是三条阶梯，每条阶梯内部的成员配方一致、只差规模，所以整个比较根本不需要训练。‘arxiv:2511.17487v2‘ 在本轮发表，为了问这个问题却还得自己做全参数微调的 Qwen3 骨干变体；这也正是它的排序只是一个不受控的点的原因。第二，测量侧的批评已经被明确提出来了：‘arxiv:2607.26191v1‘（Position: Evaluation Scores Are Perishable Knowledge Claims）指出聚合这一步属于 OWA（Ordered Weighted Averaging，有序加权平均）族、由一个悲观度参数控制，并展示同一个系统的聚合分数在取均值时是 0.79、取最小值时变成 0.41；‘arxiv:2604.25110v2‘（Knowledge Distillation Must Account for What It Loses）为每项能力定义了一个 off-metric 损失，它自带差异度量和压力分布，而该文把「可测量性」列为自己的停止限制。这两篇都把不可比性建立起来了，却都没有去测这种不可比性会对一个决策造成什么后果。第三，「把瞎猜得分测出来而不是假定」这个动作，在单轴评测里已经是成熟做法：‘arxiv:2609.32532v2‘ 在同一套关卡、同一套测评框架下跑一个均匀随机策略来估瞎猜得分，并展示某个读数约定在它面前把结论翻了过来。所以这项工作需要的工具已经存在、也验证过了，只是从来没人把它用到「不同轴上的掉分能不能相互比较」这件事上。在一张 24GB 显卡上，整个问题只需要一次可中断的推理，扫一遍冻结的题目清单；之后的全部计算都是在缓存记录上用 CPU 重算。

前作停下来，各有具体的结构性原因，不是因为马虎。‘arxiv:2511.17487v2‘ 用 Prism 式分解，提前把关注的轴定死了，排序从来不是被检验的对象，所以它不需要、也没有造出跨轴比较掉分的工具。‘arxiv:2512.16921v1‘ 认为尺子由预言器提供，这样就掩盖了一件事：探针的瞎猜得分各不相同，其上的分歧率本身也是不可比的。‘openalex:W4415269743‘（CompoDistill）只在一对师生模型上做两点对比来诊断能力损失，发现组合推理与 SFT 模型持平（它自己把这写成意外发现），然后用大约 1.2M 样本做三阶段全量微调来修复 —— 目标轴只有一条、而且是事先点名的，就不存在会不稳定的 argmax。‘arxiv:2608.01263v2‘ 把一部分教师修正方向置零，这些方向是紧凑学生模型无法表示的；它在全词表空间里为每个解码位置单独解一个投影，并在报告增益的同时列出 HallusionBench -0.53、MMStar -0.21，却没有分析这两项 —— 一个逐位置的梯度过滤器没有跨轴账本，非目标轴上的负值就无处记账。‘arxiv:2604.25110v2‘ 没有提出算子，能把两项能力的损失组合起来，所以它建立的不可比性只是让分析停在那里，没有变成一个被测出来的量。‘arxiv:2607.26191v1‘ 只有一个系统、一个标量，展示的是聚合数值的变化，而不是「被选中的那一项换人了」；而且它从未估计任何一条轴的瞎猜得分。瞎猜得分是唯一的成分：只有它能把一条轴的掉分相对另一条轴重新缩放，因此也只有它能挪动选择、而不是只挪动数值大小。‘openalex:W7154354435‘（MERIT）在事先点名的一对轴上优化一个 CMA-ES 目标，奖励时序推理的提升、惩罚时序感知的退化，并用 232 个诊断样例找回一项能力，它在适配前的检查点里本就潜在存在 —— 在一个目标函数里拿一条轴换另一条轴，前提是两者单位可比，而这个设计是假定了可比，没有去测。

这个缺口被补上之后，新增的能力是一个可以写出来的可靠性条件：给定一条规模阶梯和一组探针，每条轴在多大比例的「站得住脚的尺子」下仍然排第一，以及是否存在某条轴在所有尺子下都排第一。于是，「先诊断再修复」的流程原本消费一个排序，这个排序没有任何限定条件；现在它变成这样：修复目标能不能扛住自身的测量尺度，流程是知

道的。‘arxiv:2511.17487v2‘ 和 ‘arxiv:2512.16921v1‘ 目前都无法在自己的排序上运行这项检查；‘arxiv:2604.25110v2‘ 点明了一个限制，然后就停在那里，而这里给出的正是那个限制的可测量形式。它还给定向蒸馏这一支提供了共用的记账单位：净跨轴增益，带每条轴的带符号分量，记在同一个账本上，并在每一类尺子下都报一遍。于是，那两个数字（-0.53 和 -0.21）会被记成「退化被挪到了别处」，而不是像 ‘arxiv:2608.01263v2‘ 那样放在亮眼结论旁边、不作分析。对于云边协同部署，同一个产物还能回答一个运维问题，而聚合排行榜分数连这个问题都提不出来：边端那个成员，可以被允许丢掉哪一项能力。

方法

M0_background

钉死探针集合，并付掉那唯一一次昂贵的推理，产出逐题对错的缓存账本；后面所有计算都在它上面重算。

1. 在跑任何模型之前，先把四个轴探针和它们的答案键固定下来。物体幻觉：POPE 的 random/popular/adversarial 三个设置（‘arxiv:2305.10355v3‘）。细粒度定位：RefCOCO/RefCOCO+/RefCOCOg 验证集，取其中的指代表达式，判定标准是 IoU（交并比）达到 0.5 才算对。一致性：一套脚本生成的题集，要求同一个问题的 5 种改写全部答对才算通过，做法是对每个 MMBench 式题干套用 ‘$p_{para} = 5$‘ 条固定模板改写。多步推理：MMStar。每个轴探针至少要有 ‘$n_{min} = 800$‘ 道题。这个下限原先钉在 200，后来被提高了，原因是实际跑完的扫描显示：在题目偏薄的改写一致性轴上，200 题时噪声导致的翻转率 ‘$F_{noise} = 0.360$‘，而尺子导致的翻转率 ‘$F_{scale} = 0.417$‘，两者只差 0.057，撑不起核心结论；题量变成 4 倍之后，‘F_{noise}‘ 降到 0.190。
   为什么： 整篇的主张是「决定结论的是尺子，不是数据」，所以数据必须先钉死。而且题量下限应该取一个实测值 —— 分离度正是在这个题量上被测出来，而不是按惯例挑一个整数。‘$n_{min} = 800$‘ 是实测的功效下限，这样写还有一个好处：任何题量不足的阶梯，在构造上就能被识别出来。
2. 对每个已发布的检查点各跑一次推理 —— Qwen2.5-VL 3B/7B、InternVL3 1B/2B/8B、LLaVA-OneVision 0.5B/7B —— 用 fp16、贪心解码，扫完整份题目清单。每道题都记下原始生成文本、解析出的答案、对错位，以及一个解析失败标记。得到的产物是账本 L：每个（检查点，轴，题目）一行，分片存储并带断点，所以这一遍可以中断后续跑。
   为什么： 这是唯一昂贵的一步，而且只付一次。缓存逐题对错、而不是缓存每条轴的汇总分，这正是让后面所有尺子、重采样和归因都变成 CPU 重算的关键。这条成本性质在这里是承重的，因为本文的贡献是把已经存在的证据重新读一遍，不是搞一场训练。

M1_measured_scale_family

用不看输入的退化答题器测出每个探针的瞎猜得分，再把一族站得住脚的尺子实现成账本的全定义函数，并压到它的可辨识等价类。

3. 用四个不看输入的「退化答题器」跑同一份题目清单，记录每个轴探针测出来的瞎猜得分 ‘c_a‘：POPE 用一律回答”no”；定位轴用一个放在图像正中的框，面积取训练集框面积的中位数；改写一致性轴用一个固定不变的回答；MMStar 用固定随机种子下的均匀随机选项。同时记录 ‘u_a‘，也就是同家族最大成员在每条轴上的分数。这些瞎猜得分是算出来的，不是外部给定的。
   为什么： 测出来的瞎猜得分，正是本文与另一种做法的分界线：那种做法凡是二分类就假定 0.5。它也是整个机制所依赖的那个量 —— 测出来的 c 向量是承重变量，后面的负对照会专门把它换成一个预言值。我们承认「测而不是假定瞎猜得分」本身已是成熟做法：‘arxiv:2609.32532v2‘ 就是在同一套关卡、同一套测评框架下用均匀随机策略这么做的。我们主张的只是把它用到跨轴可比性上。
4. 把量尺算子实现成账本的一个全定义纯函数。给定一组设置 g，它跨五个坐标取值 —— 掉分约定、瞎猜得分校正、余量（headroom）归一化、轴内 OWA（有序加权平均）悲观度 ρ（在 $[0, 1]$ 上按 0.25 取网格）、以及解析失败的处理方式 —— 函数返回某一个阶梯步（小成员对大成员）上的逐轴退化向量。用两组手算设置来核验这个算子；已确认瞎猜得分校正恰好把绝对掉分放大 ‘$1/(1 - c_a)$‘ 倍，误差在 1e-12 以内。*底线校正把原始轴分数映射为扣除随机水平后的能力值，因此绝对降幅被精确放缩 $1/(1 - c_a)$ 倍。POPE 实测底线约 0.50、定位约 0.02，两者降幅分别乘以 2.000 与 1.020；这正是探针构造影响跨轴比较的唯一通道。*

$$\tilde{x}_{m,a} = \frac{x_{m,a} - c_a}{1 - c_a}, \qquad \Delta_a^{\text{corr}} = \tilde{x}_{L,a} - \tilde{x}_{s,a} = \frac{1}{1 - c_a}\left(x_{L,a} - x_{s,a}\right) \tag{1}$$

   为什么： 这一族被枚举出来的尺子必须是缓存账本的函数，不能依赖重跑模型，否则「只有尺子在变」这个主张就无法检验。五个坐标故意混了两类：纯约定（掉分、余量、OWA）和测出来的仪器性质（瞎猜得分、解析失败的截断率）。混进测出来的那一类是有用的，因为正是它们让主导坐标可以事先预测，而不是事后才发现。
5. 用三道会被报出来的护栏让算子全定义，而不是悄悄截断，并且每一类都计数。(i) 瞎猜得分定义域护栏：某条轴的观测分落在它自己的瞎猜得分上或以下（‘$x_s <= c_a$‘），其校正后的能力就不可辨识，因此在所有做了瞎猜得分校正的设置下，这条轴都被排除在 argmax 竞争之外，排除次数按阶梯报出来。(ii) 零分母护栏：相对掉分在分母为零时无定义（原始的 ‘$x_L = 0$‘，或校正后的 ‘$x_L = c_a$‘），这类格子记为未定义，而不是硬算。(iii) 余量符号护栏：当小成员在某条轴上分数超过家族里最大的成员时，余量项 ‘$(u_a - x_s)$‘ 会变成负数，于是一条其实变好了的

轴，反而会被排成退化最严重的那条；所以 ‘$x_s >= u_a$‘ 的格子记为未定义并计数。*在剩余空间归一化之下，底线校正是严格不可识别的：分子分母中的 $(1 - c_a)$ 因子完全抵消。这正是名义上 $2x2x3x5x2 = 120$ 个设定只是参数化、而非彼此相异的度量尺的原因；在一个现实的四轴实例上，(降幅约定, 底线, 剩余空间) 子网格从 12 种组合折叠为 5 种相异排序。因此保持率必须在可识别等价类上报告，并附折叠对照表。*

$$\Delta_a^{\mathrm{corr,head}} = \frac{\tilde{x}_{L,a} - \tilde{x}_{s,a}}{\tilde{u}_a - \tilde{x}_{s,a}} = \frac{x_{L,a} - x_{s,a}}{u_a - x_{s,a}} = \Delta_a^{\mathrm{head}} \tag{2}$$

*为什么：*每道护栏都堵住一种具体途径：用算术把 argmax 制造出来。一个低于瞎猜得分的分数，如果被 ‘$1/(1 - c_a)$‘ 放大，否则就会在表里给出看起来最大的掉分。第三种情形不是假想：‘arxiv:2512.16921v1‘ 报出过一些类别上 28B 模型不如 3B 模型，说明符号反转在真实数据里确实会发生，而报出它出现的频率本身就是发现的一部分。

6. 在汇报任何结果之前，先把标称的设置网格压到它的可辨识商集：按设置所产生的逐轴退化向量把设置分成等价类，同时报出标称个数和真正互不相同的类数，并把折叠表列出来。在余量归一化之下，瞎猜得分校正是严格不可辨识的，因为 ‘$(1 - c_a)$‘ 这个因子被约掉了：对两种余量选择而言，(绝对, 已校正, 余量) 与 (绝对, 未校正, 余量) 取值完全相同；(相对, 已校正, 无余量) 与 (绝对, 未校正 , ‘$x_L - c_a$‘) 取值也完全相同。在一个现实的四轴实例上，标称的 2x2x3x5x2 = 120 组设置中，(掉分, 瞎猜得分, 余量) 这个子网格从 12 种组合折叠成 5 类，它们给出的排序互不相同。*$argmax$ 保持率是在相异度量尺等价类集合 G 中，轴 a 占据最劣位置的比例；翻转率为 1 减去保持率最高者。保持率为 1 的轴构成稳定轴集合，集合为空意味着没有任何结论能在整个尺度族下存活。在已执行的实例上，完整扫描使 $argmax$ 在三个不同轴间移动，翻转率为 0.417；而独立构造的朴素基线（仅用三种教科书式度量尺）给出一致结论，翻转率为 0.000。*

$$\pi_f(a) = \frac{1}{|G|} \sum_{g \in G} \mathbf{1}\left[a = \arg\max_{a'} \Delta_{a'}^{(g)} \right], \qquad F_f = 1 - \max_a \pi_f(a) \tag{3}$$

*为什么：*拿 120 种参数化来报保持率，是把分母注水，审稿人有理由据此拒稿。在可辨识商集上汇报才是诚实的口径。而且这种不可辨识性本身就是一项发现，不只是记账：它说明任何一项审计，只要先按瞎猜得分做了校正、再按余量做归一化，就等于悄悄把自己的校正撤销了。

M2_verdict_stability

把这一族尺子转成 $argmax$ 保持率、把尺子导致的翻转与噪声导致的翻转分开的翻转率，以及逐坐标归因 —— 到底是哪个分析选择挪动了结论。

7. 对每个阶梯步，在账本 L 上做 ‘$n_{boot} = 1000$‘ 次题目级自助重采样，在每个重采样上评估每一个互不相同的尺子类，差距在 ‘delta_tie = 0.01‘ 以内就标为平局，然后归约出：每条轴的 argmax 保持率 ‘pi_f‘；翻转率 ‘$F_f = 1 - max_a pi_f(a)$‘；稳定轴集合；‘F_{scale}‘，即在自助中位数上跨尺子类的翻转率；以及 ‘F_{noise}‘，即跨重采样的翻转率，其设置取已发表审计隐含使用的那一套常规设置（绝对掉分、不做瞎猜得分校正、不做余量归一化、$\rho = 0.5$、解析失败判错）。‘F_{scale}‘ 和 ‘F_{noise}‘ 并排汇报，两者都带自助区间。若某个阶梯步的各条轴全部打平，‘pi_f‘ 无定义，该阶梯步被排除并列出。
*为什么：*这一步是正面迎上那个危险的测量侧替代解释，而不是绕开它。有 ‘arxiv:2607.26191v1‘ 在前，审稿人怀疑整个效应只是薄探针上的抽样噪声，这种怀疑是合理的；而实际跑完的扫描证明这个风险真实存在：在原先 200 题的下限上，分离度只有 0.057。这条汇报规则是双向约束的 —— 某条阶梯的 ‘F_{scale}‘ 区间，若没有超出 ‘F_{noise}‘ 的区间，就把这条阶梯写成「受噪声限制」发表出来，而不是压下不提。

8. 对五个坐标逐个处理：把该坐标冻结在它的常规取值上、其余坐标照常扫描，重算翻转率 F，并把 F 的下降量作为该坐标的翻转份额报出来。份额在可辨识的尺子类上归因，这样某个坐标如果与另一个坐标组合起来不可辨识，就不会被重复记功。预测排在第一行的是瞎猜得分校正，事先给出的理由是那条反转带 $(0.5102, 1.0)$，它占了比值空间的 48.98%。*反转边界由 $E1$ 直接代数推出：当未校正降幅之比跨过 $(1 - c_{max})/(1 - c_{min})$ 时，该轴对的排序必然互换。对实测底线 0.50 的二元轮询探针与 0.02 的定位探针，该区间为 $(0.5102, 1.0)$，占比值空间的 48.98%，因此排序翻转取决于具体阶梯，既非必然也非不可能。*

$$\frac{\Delta_a}{\Delta_b} \in \left(\frac{1 - c_{\max}}{1 - c_{\min}},\ 1 \right) \iff \arg\max_{\{a,b\}} \Delta^{\mathrm{corr}} \neq \arg\max_{\{a,b\}} \Delta \tag{4}$$

*为什么：*这一步把一份离散度报告变成关于仪器的因果陈述。由于主导坐标是在算表之前就由 ‘$1/(1 - c_a)$‘ 预测出来的，这项归因是一次检验，而不是事后去读一条规格曲线。它同时也把本文与朴素基线的决定性差别隔离出来 —— 那个基线完全没有做余量归一化。

M3_budget_consequence

用缓存好的教师监督和四个步数对齐的 $LoRA$ 臂，在预算对齐的条件下把相互竞争的结论真的花掉，并按净跨轴增益、附每条轴的带符号分量来评分。

9. 让同家族里较大的那个成员（Qwen2.5-VL 7B）在各修复臂的训练混合数据上跑一遍，在每个位置上取 $top -$ ‘$k_{logit} = 50$‘ 个 logits，缓存到磁盘。

*为什么：*在一张 24GB 卡上，常驻的教师模型和一个 3B 学生模型共存并不舒服；而且各臂必须步数对齐才能比较。做了缓存，监督信号就是静态的，于是四个臂除了数据混合不同，其余条件完全一致。

10. 在该家族最小的成员上训练四个步数对齐的 LoRA（低秩适配）臂，每个臂都恰好跑 ‘$S_{steps} = 1000$‘ 个优化步，‘$r_{lora} = 16$‘，‘alpha_lora = 32‘，‘lr = 1e-4‘：臂 A1 用排第一的那条轴的数据（按 ‘pi_f‘ 排序），臂 A2 用排第二的那条轴，臂 U 用同等规模但与轴无关的混合数据，臂 N 什么都不做。每个臂的适配器会在解码时改变学生模型的生成内容，生成内容改变会改变解析出的答案，答案改变又会改变账本 L 里的对错位 —— 所以这次干预是在答案层面被观测到的，不只体现在损失上。
    *为什么：*这一条腿是本文与多重宇宙分析（multiverse analysis）的分界。多重宇宙报告的是一个连续效应的离散度，整个过程没有选择这一步；而这里两个存活下来的结论被真的花掉了，预算还是对齐的，于是问题变成：排第一的那条轴到底是哪一条，这件事能换来什么。
11. 对每个被适配过的学生模型，在完整的四轴题目清单上重跑第 2 步（对每个已发布的检查点各跑一次 ...）的推理，把结果追加到账本 L，然后在每一个互不相同的尺子类下重算净跨轴增益 —— 也就是把四条轴上训练后减训练前的分数带符号求和 —— 并附上每条轴的带符号分量一起汇报。*跨轴净增益是四条轴上「训练后减训练前」分数的带符号求和，在每个相异度量尺等价类上连同各轴分量一并报告，使被转移的退化保持可见而不被总分吸收。这正是逐位置梯度过滤（如 Fisher 投影蒸馏）在结构上无法构造的核算单位，也是其 $HallusionBench$ -0.53 与 $MMStar$ -0.21 只能与增益并列而无从分析的原因。*

$$G_{\text{net}}(\text{arm}) = \sum_{a=1}^{4} \left(x_{s,a}^{\text{post}} - x_{s,a}^{\text{pre}} \right) \tag{5}$$

    *为什么：*一个定向增益如果只是把退化挪到了别处，那不算修复；而只看单条轴的亮眼数字，是分不出这两种情况的。同一个共享账本上的带符号分量，正是这里需要的那种记账；而 ‘arxiv:2608.01263v2‘ 在增益旁边列出 HallusionBench -0.53 和 MMStar -0.21，却没有分析。

M4_validation

用植入最差轴的预言实例检验估计器，跑同质瞎猜得分的负对照，然后把逐阶梯的画像作为部署选择用的产物交付出去。

12. 生成合成的对错记录，其中最差的轴、以及每条轴的瞎猜得分，都是人为植入的；然后原封不动地在这些记录上跑第 4 步（把量尺算子实现成账本的一个全 ...）到第 8 步（对五个坐标逐个处理），检查两件事：当各条轴的瞎猜得分相同时，估计器能否找回植入的最差轴；当它们不相同时，估计器能否复现预测的反转边界。这条边界就是未校正的掉分比值穿过 ‘$(1 - c_{max})/(1 - c_{min})$‘ 的位置。一个投票式探针的瞎猜得分是 0.50，一个定位探针是 0.02；对这一对探针，边界给出 $(0.5102, 1.0)$。
    *为什么：*上游所有测量都做在真实最差轴未知的模型上，所以找回率否则只能靠假定。在这里，真值是构造出来的、已知的，而且不来自被评估的检查点，这就让估计器的正确性变成可测量的，而不是靠论证。
13. 把测出来的瞎猜得分向量换成一个同质向量（每个 ‘c_a‘ 都设为均值 c-bar），重跑第 4 步（把量尺算子实现成账本的一个全 ...）到第 8 步（对五个坐标逐个处理）以及选臂，读出现在被选中的是哪条轴，以及那个臂此前已经测好的净跨轴增益。其他一切都不动 —— 检查点、题目、原始回答、自助重采样、OWA 网格。然后把这份画像作为部署选择用的产物汇报出来，配一小节讲云边协同的接口，不引入任何新机制。
    *为什么：*这个对照把测出来的瞎猜得分向量隔离出来，确认它是量尺不一致进入决策的唯一通道，并且把预测效果写在下游任务结果指标上，而不是写在翻转率上。部署这层框定是这个产物赢得发表场合的地方：对于一个要把缩小后的模型卸载到边端的运维方来说，‘pi_f‘ 加上每条轴的交换明细，才是决定依据 —— 边端成员可以被允许丢掉哪项能力，由它说话；而这是单一的聚合排行榜分数表达不出来的。